

# 大模型安全检测评估技术综述

胡斌<sup>1</sup>, 黑一鸣<sup>2</sup>, 吴铁军<sup>3</sup>, 郑开发<sup>4,5</sup>, 刘文忠<sup>6</sup>

(1. 华中科技大学计算机科学与技术学院, 武汉 430074; 2. 中国信息通信研究院人工智能研究所, 北京 100083; 3. 东南大学计算机科学与工程学院, 南京 210096; 4. 浙江大学计算机科学与技术学院, 杭州 310027; 5. 北京神州绿盟科技有限公司, 北京 100089; 6. 北京理工大学计算机学院, 北京 100081)

**摘要:**随着人工智能技术快速发展,大语言模型(LLM)凭借其强大的自然语言处理能力已在科研、教育、金融、医疗等许多领域崭露头角。然而,在LLM被广泛使用的过程中,伴随一系列安全问题:如存在偏见、歧视的风险,存在生成有害内容的风险,存在泄露用户隐私信息的风险,存在信息误导性传播的风险以及容易受到恶意对抗攻击等安全风险。上述风险可能对用户造成损害,甚至影响社会稳定及伦理秩序,因此需要对LLM进行全面安全检测评估。文章针对目前关于LLM安全性检测评估的相关研究内容,归纳总结常见的安全风险类型,并对已提出的主流安全检测评估技术或方法进行综述,同时介绍相关评估方法、评估指标、常用数据集和工具,归纳国内外关于大模型安全评估出台的重要参考标准、规范。此外,文章还讨论了安全对齐的技术理念、原理、功能实现机制及安全对齐技术评价体系。最后,通过分析当前LLM安全检测评估面临的问题,展望未来技术发展趋势和研究方向,旨在为学术界、产业界的相关研究和实践提供参考。

**关键词:**大语言模型;检测评估;安全风险;评估标准;对抗攻击

**中图分类号:** TP309 **文献标志码:** A **文章编号:** 1671-1122(2025)10-1477-16

中文引用格式:胡斌,黑一鸣,吴铁军,等.大模型安全检测评估技术综述[J].信息安全,2025,25(10):1477-1492.

英文引用格式:HU Bin, HEI Yiming, WU Tiejun, et al. A Review of Safety Detection and Evaluation Technologies for Large Models[J]. Netinfo Security, 2025, 25(10): 1477-1492.

## A Review of Safety Detection and Evaluation Technologies for Large Models

HU Bin<sup>1</sup>, HEI Yiming<sup>2</sup>, WU Tiejun<sup>3</sup>, ZHENG Kaifa<sup>4,5</sup>, LIU Wenzhong<sup>6</sup>

(1. College of Computer Science and Technology, Huazhong University of Science and Technology, Wuhan 430074, China; 2. Artificial Intelligence Research Institute, China Academy of Information and Communications Technology, Beijing 100083, China; 3. School of Computer Science and Engineering, Southeast University, Nanjing 210096, China; 4. College of Computer Science and Technology, Zhejiang University, Hangzhou 310027, China; 5. Beijing Shenzhou NSFOCUS Technology Co., Ltd., Beijing 100089, China; 6. School of Computer Science, Beijing Institute of Technology, Beijing 100081, China)

收稿日期:2025-06-15

基金项目:国家重点研发计划[2022YFB3104900];北京市高层次创新创业人才支持计划科技新星计划[20250484975];山东省自然科学基金[ZR2024MF084]

作者简介:胡斌(1979—),男,湖北,正高级工程师,博士,主要研究方向为大语言模型安全、网络安全风险治理、软件供应链安全;黑一鸣(1994—),男,山东,工程师,博士,主要研究方向为应用安全、内容安全和网络安全;吴铁军(1979—),男,湖北,高级工程师,博士,主要研究方向为网络空间安全、流量行为分析、恶意流量识别;郑开发(1989—),男,湖北,高级工程师,博士,主要研究方向为网络空间安全、数据安全、舆情分析;刘文忠(1984—),男,湖北,硕士研究生,主要研究方向为网络安全风险评估、网络安全等级保护测评、工业自动化安全评估。

通信作者:郑开发 zhengkafa@zju.edu.cn

**Abstract:** With the rapid development of artificial intelligence technology, large language models (LLMs) have emerged in many fields such as scientific research, education, finance, and healthcare due to their powerful natural language processing capabilities. However, as LLMs are widely adopted, they bring a series of security issues: risks of bias and discrimination, potential generation of harmful content, threats to user privacy leakage, risks of misleading information dissemination, and vulnerabilities to malicious adversarial attacks. These risks may harm users and even impact social stability and ethical order, necessitating comprehensive security testing and evaluation of LLMs. This article primarily focused on current research on LLM security assessment, categorizing common security risks and reviewing mainstream security evaluation techniques. It also introduced relevant assessment methods, metrics, commonly used datasets, and tools, while summarizing key security evaluation standards and guidelines developed globally. Additionally, the paper discussed the technical concepts, principles, and implementation mechanisms of safety alignment, along with its evaluation framework. Finally, by analyzing the challenges faced in current LLM security assessment, it outlined future technological trends and research directions, aiming to provide guidance for academic and industrial research and practices.

**Key words:** LLM; detection and evaluation; security risks; evaluation standards; adversarial attacks

## 0 引言

近年来,以GPT为代表的大语言模型(Large Language Models, LLM)在技术层面取得了突破性进展,展现出卓越的语言理解、文本生成及问题解决能力,其应用已广泛渗透至金融、医疗、自动驾驶等关键领域<sup>[1-3]</sup>。然而,这类技术也暴露出生成歧视性内容、传播虚假信息、泄露个人隐私、辅助钓鱼诈骗及生成恶意代码等安全隐患<sup>[4]</sup>,严重削弱了公众对LLM技术的信任基础。为应对大模型存在的系统性安全风险,亟需构建一套科学的安全检测评估体系,通过早期缺陷识别与修复提升模型鲁棒性,同时为监管决策提供数据支撑,从而增强用户信心并保障LLM在多场景下的合规应用<sup>[5]</sup>。

当前,国内外学术界与产业界已围绕LLM安全挑战展开多项探索。主流研究将安全风险划分为功能安全风险、信息安全风险和个人隐私风险3个维度<sup>[6]</sup>,并相继推出系列评估基准与工具。开放式Web应用程序安全项目(Open Web Application Security Project, OWASP)发布《大语言模型安全测评基准V1.0》及《LLM安全与治理检查清单》<sup>[7]</sup>,IEEE主导P3419《大语言模型评测》标准制定<sup>[8]</sup>,中国电子技术标准化研究院等

机构开展“大模型标准符合性评测”项目<sup>[9]</sup>。这些举措显著推动了行业规范化进程。但需要指出的是,现有研究仍存在明显局限:评估框架多聚焦单一风险类型,缺乏系统性整合;方法论上存在标准不统一、数据集质量依赖性强及评估主观性过高等问题;面对新型攻击手段的快速迭代,现有体系在动态适应性和响应速度方面表现不足<sup>[10]</sup>。

## 1 LLM 安全风险概述

LLM的安全风险贯穿于模型生命周期的各个阶段,从数据收集、训练微调到最终的部署应用,每个环节都可能引入或暴露安全问题。LLM存在的安全风险分为3大类、12小类<sup>[11,12]</sup>,如图1所示。

| 功能安全风险          | 信息安全风险          | 个人隐私风险          |
|-----------------|-----------------|-----------------|
| 风险1-1<br>生成有毒内容 | 风险2-1<br>后门攻击   | 风险3-1<br>个人隐私泄露 |
| 风险1-2<br>偏见     | 风险2-2<br>数据投毒攻击 | 风险3-2<br>成员推断攻击 |
| 风险1-3<br>幻觉     | 风险2-3<br>对抗性攻击  | 风险3-3<br>数据提取攻击 |
| 风险1-4<br>越狱     | 风险2-4<br>提示注入   | 风险3-4<br>用户输入隐私 |

图 1 LLM 安全风险矩阵

## 2 LLM 安全检测评估的核心技术

针对这些风险,现有检测评估技术主要从安全性、鲁棒性和可靠性3个维度展开,为模型优化与安全部署提供数据支撑<sup>[13-15]</sup>。本章重点总结偏见与公平性、有害内容生成、隐私泄露风险、误导性信息与幻觉、对抗性攻击与鲁棒性测试5类关键技术,并从评估方法、评估指标、常用数据集及工具等方面进行系统论述。

### 2.1 偏见与公平性评估技术

偏见与公平性评估技术旨在检测和量化LLM在处理不同群体时可能产生的不公平或偏见现象,其核心目标包括3点:1)识别模型输出中存在的偏见倾向;2)防止LLM生成具有歧视性的内容;3)消除针对特定群体特征的差异化对待行为<sup>[16]</sup>。

#### 2.1.1 评估方法

偏见与公平性评估主要采用基于上下文、基于生成文本、特定任务场景以及专业测试题库4种方法。1)基于上下文的评估方法:通过设计融合社会文化背景的上下文探针任务,检测模型对不同群体输入的响应差异,从而识别潜在的偏见倾向<sup>[17]</sup>。2)基于生成文本的评估方法:对模型输出内容进行系统性分析,重点检测是否存在针对特定群体的刻板印象、歧视性表述或不公正的文本表征。3)特定任务场景评估方法:模拟招聘、信贷等实际应用场景,通过设计具有代表性的任务流程,评估模型在真实使用环境中的偏见表现。4)专业测试题库评估方法:采用DIKWP<sup>[18]</sup>等标准化测评工具,通过结构化题库系统检验模型在不同维度下的公平性表现,实现跨模型的横向比较。

这些评估方法从不同维度构建了完整的偏见检测体系,为模型优化提供了多维度的评估依据。偏见与公平性评估方法<sup>[19]</sup>对比如表1所示。

#### 2.1.2 评估指标

偏见与公平性评估技术主要包含统计偏差、平等机会、平均绝对偏差、影响差异和敏感词关联度等核心指标。统计偏差关注不同敏感属性群体预测值间的系统性差异,其核心假设是理想状态下各群体的预测

表1 偏见与公平性评估方法对比

| 评估方法        | 评估对象              | 技术手段                     | 典型应用场景                | 核心优势                 |
|-------------|-------------------|--------------------------|-----------------------|----------------------|
| 基于上下文的评估    | 模型对不同社会/文化背景的响应差异 | 设计特定上下文探针,观察模型行为偏差       | 检测招聘对话中是否存在性别歧视倾向     | 揭示隐性偏见,反映现实情境中的公平性缺陷 |
| 基于生成文本的评估   | 模型自由生成内容的偏见性      | 分析输出文本中的刻板印象、歧视性描述或不公平表述 | 评估故事生成中对特定群体的负面刻画     | 直接捕捉模型自发输出的有害内容      |
| 特定任务场景评估    | 模型在现实决策任务中的公平性    | 模拟应用场景,量化不同群体间的结果差异      | 测试医疗诊断模型对不同种族患者的准确性差异 | 关联实际风险,为落地部署提供可靠性依据  |
| 基于专业测试题库的评估 | 模型系统性偏见表现         | 使用结构化测试集,覆盖多维度偏见场景       | 全面检测模型在法律咨询、教育辅导中的公平性 | 标准化测评,支持跨模型横向对比      |

分布应保持一致<sup>[20]</sup>;平等机会则聚焦于检验不同群体中合格个体获得积极预测的概率是否均等<sup>[21]</sup>;平均绝对偏差通过量化模型预测值与真实值的偏离程度,因其对异常值不敏感的特性成为常用评估工具<sup>[22]</sup>;影响差异专门用于分析模型二元决策对不同群体产生的后果差异,旨在识别系统性排斥风险;敏感词关联度通过计算语言表征中敏感属性词与刻板印象属性词的条件概率比值<sup>[6,7]</sup>,揭示模型潜在的偏见倾向<sup>[23]</sup>。这些指标从不同维度构建了完整的偏见评估体系,为开发人员全面理解模型性能、针对性优化公平性提供了量化依据。

#### 2.1.3 常用数据集及工具

偏见与公平性评估中,以下数据集和工具发挥着重要作用。在数据集方面,Adult Income数据集通过分析不同性别和种族群体的收入预测结果,能够有效检测模型在就业歧视等方面的偏见倾向;Wiki BIOS数据集通过记录人物的职业信息等事迹,为评估职业偏向和性别偏向提供了客观依据,有助于开发者优化算法以提升数据集的公平性<sup>[24]</sup>。工具方面,IBM开源的AIF360是一个Python通用库,它提供数据和模型公平性评估指标及偏见缓解算法,支持多样化的公平性度量分析,并能根据用户反馈持续优化模型中的偏见问题。微软开发的Fairlearn同样是基于Python的开源工具,它提供公平性评价指标和偏见缓解算法,帮助用户发现并减少机器学习模型中的偏见,从而获得更公平的模型结果。这些工具和数据集为偏见与公平性评估提



供了全面的技术支撑。

## 2.2 有害内容生成评估技术

有害内容生成评估技术主要用于检测和识别LLM生成的文本是否包含暴力、色情、恐怖主义、仇恨言论等不当内容。该技术的核心目标包括：防止LLM被用于传播或支持不良信息；保护用户免受有害内容影响；确保模型输出符合社会道德规范和法律法规要求<sup>[25]</sup>。通过系统化的评估方法，该技术能够有效识别和过滤具有潜在危害的生成内容，为模型的合规应用提供保障。

### 2.2.1 评估方法

有害内容生成评估<sup>[26]</sup>已形成了自动化工具与人工评估的人机协同检测体系，其效率、成本、语义理解深度和适用阶段如表2所示。

表2 有害内容生成评估方法对比与适用性

| 方法             | 效率    | 成本    | 语义理解深度 | 适用阶段      |
|----------------|-------|-------|--------|-----------|
| 关键词/正则匹配       | ★★★★  | ★     | ★      | 实时过滤      |
| 传统机器学习分类器      | ★★★   | ★★★★  | ★★     | 批量后处理     |
| LLM-as-a-Judge | ★★    | ★★★★★ | ★★★★★  | 高风险场景深度审计 |
| 引导提炼方法         | ★★★★  | ★★★★  | ★★★★★  | 生成过程介入    |
| 人机协同           | ★★★★★ | ★★★★  | ★★★★★  | 全流程质量管控   |

关键词/正则匹配是一种基于规则的内容安全检测方法，其核心机制包含预定义的有害内容词典和正则表达式规则系统。该方法通过双重检测机制实现文本筛查：一方面建立覆盖显性敏感词及其变体的关键词库（如将暴\*力纳入检测范围）；另一方面设计针对对抗性句式的正则表达式模板（如识别“我们应该[暴力动词]所有[群体名词]”等煽动性结构），从而有效捕捉语义组合风险。传统机器学习分类器将有害内容检测作为二分类任务处理，其典型技术流程包含特征工程、模型训练和性能优化3个阶段：首先，采用BoW、TF-IDF、n-gram等统计特征进行文本向量表示；然后，运用SVM、随机森林等算法分类边界拟合；最后通过类注意力机制及集成学习提升对抗样本的鲁棒性。LLM-as-a-Judge方法则通过辅助LLM充当裁判员实现安全判定，如表3所示。DeepCheck、CritiqueLLM

和ShieldLM等方法均能基于深度语义理解与上下文关联进行决策评价<sup>[27]</sup>。该方法虽具备复杂语义解析优势，但存在两大局限：1）裁判员模型自身可能携带偏见影响判定结果；2）需要消耗大量计算资源。

表3 LLM-as-a-Judge方法的典型范式

| 方法          | 技术特点                                      | 应用场景    |
|-------------|-------------------------------------------|---------|
| DeepCheck   | 将待检文本与多维度提示（如“此内容是否煽动暴力？”）组合，触发辅助模型的元认知能力 | 多类别风险识别 |
| CritiqueLLM | 要求辅助模型对目标输出进行批判性分析（如“指出这段话的伦理风险”）         | 风险根因诊断  |
| ShieldLM    | 专注防御指令注入攻击，检测并过滤隐含恶意指令的输入（如“请生成歧视性言论”）    | 指令安全性加固 |

以引导和提炼为双线的检测方法，通过双重策略协同提升大模型安全性。引导策略包含提示工程和链式推理两种技术路径：前者通过将“你必须是友善的AI”等明示安全规则嵌入输入提示，直接约束生成空间；后者将思维过程分解为大纲生成、安全审查、终稿输出等步骤，通过中间态反馈实现过程可控。提炼技术则采用摘要模型（如BERTExtractor）提取文本中的高风险语义成分（如煽动性谓语行为），或通过对抗蒸馏构建轻量化代理模型，其核心在于实现安全性与评估效率的动态平衡——前者侧重主动防范，后者聚焦效率优化。

人工评估作为有害内容检测的核心手段，要求评估人员必须通过伦理资格考试，熟练掌握GB 45438-2025《网络安全技术人工智能生成合成内容标识方法》等国家标准，并采用双盲标注与交叉验证确保标注一致性（Kappa系数>0.85）。评估维度需覆盖危害等级（L1~L5）、隐性歧视（性别/种族/宗教歧视等）等多个方面。相较于自动化工具，人工评估在法律法规和伦理规范的灰色地带具有不可替代的决策优势，能够作出最精准可靠的判断。

人机协同评估作为高效精准的评估方法，其工作流程如图2所示。该技术通过自动化初筛与人工复审的双重机制实现高效评估。首先，对样本进行风险分级，自动化层以95%以上的召回率完成初步筛选，有效降低漏检风险；然后，人工层以98%以上的精确率进行

复核,显著减少误判可能;最后,通过自动归档形成标准化标注库。该技术已广泛应用于社交媒体内容审核、AI生成新闻合规审查等领域,充分发挥机器高效筛查与人工精准判断的协同优势,使内容安全水平得到显著提升。




图2 人机协同评估工作流程

### 2.2.2 评估指标

有害内容生成评估的核心指标包括毒性评分、有害内容生成率和攻击成功率3个指标。毒性评分通过基于BERT的Detoxify等模型对文本进行分析,量化文本中冒犯性、有害或不适宜语句的比例,输出0~1的评分值,该指标能有效识别潜在危害信息,评分越高表明文本对用户的不良影响风险越大。有害内容生成率通过OpenAI Content Policy API或自定义分类器统计模型输出中违反内容政策的有害内容占比,直接反映模型产生违规内容的倾向性,为安全性能评估提供量化依据。攻击成功率评估模型的抗攻击能力,采用A\*算法等模拟对抗性输入,统计模型被成功诱导生成有害内容的比例,该指标能准确反映模型在面临恶意攻击时的脆弱性。这3个指标从不同角度构建了有害内容生成评估的完整体系,为模型安全性能提升提供了多维度的改进方向。

### 2.2.3 常用数据集及工具

在有害内容生成评估领域,以下数据集和工具发挥着关键作用。数据集方面,HateAI-100作为专门用于检测大模型生成文本有害性的样本集,包含人类生成和大模型生成的多样化样本;MultiJail是一个多语言越狱场景模拟数据集,既可用于检测模型对恶意指令的响应能力,又能有效识别模型潜在的安全隐患<sup>[28]</sup>。工具方面,IBM开发的AIF360是一个开源的Python软

件包,提供全面的公平性指标和偏见缓解方法,帮助用户量化评估数据集或模型中的偏见并进行针对性调整;微软推出的Fairlearn专注于模型预测结果公平性评估的Python库,提供系统的评估指标和消偏方案<sup>[29]</sup>。这些工具为有害内容检测提供了专业的技术支持。

## 2.3 隐私泄露风险评估技术

隐私泄露风险评估技术主要用于量化衡量LLM在应用过程中可能导致的个人数据泄露风险,包括手机号码、姓名等个人身份信息(Personally Identifiable Information, PII)的直接或间接暴露。该技术的核心目标是确保用户隐私安全,防止模型在训练或使用过程中因数据管理不当导致个人隐私、商业机密等敏感信息泄露。以下将系统介绍当前业界主流的评估方法、关键评估维度以及常用的数据集和工具。

### 2.3.1 评估方法

隐私泄露风险评估技术主要包括成员推断攻击、数据提取攻击、属性推断攻击和训练数据记忆风险评估等方法。成员推断攻击通过分析模型对特定特征数据的响应模式,判断该数据是否存在于训练集中,攻击者通过构造与目标数据相似的样本,并根据模型输出置信度或行为特征实现推断<sup>[30]</sup>。数据提取攻击采用精心设计的提问策略,通过反复交互迫使模型逐字输出训练数据中的原始内容<sup>[31]</sup>。属性推断攻击在已知目标数据属于训练集的前提下,进一步推断其关联的非公开敏感属性信息<sup>[32]</sup>。训练数据记忆风险评估主要检测模型对训练数据的记忆程度,重点关注个人身份信息及代表性词语片段的泄露风险,通过构建包含特定信息的句子测试模型是否会产生数据泄露,该方法可分为单词序列型和关键词型两种评估模式<sup>[33]</sup>。表4详细对比了各类隐私泄露风险评估方法的技术特点、应用场景和风险。

### 2.3.2 评估指标

隐私泄露风险评估技术主要包含隐私泄露比例、隐私泄露系数、攻击成功率和隐私泄露风险等级4个核心指标。隐私泄露比例通过成员推断攻击和数据提

表 4 隐私泄露风险评估方法对比

| 评估方法       | 核心攻击目标            | 攻击机制                            | 典型场景                | 关键风险                |
|------------|-------------------|---------------------------------|---------------------|---------------------|
| 成员推断攻击     | 判断特定数据点是否在训练集中    | 输入相似样本，观察模型输出置信度或行为差异           | 模型训练数据是否存在某用户病历     | 暴露数据参与情况，违反数据匿名性    |
| 数据提取攻击     | 恢复训练数据中的原始敏感信息    | 通过精心设计的提示 / 重复提问，诱导模型逐字输出训练数据片段 | 提取模型记忆的身份证号、银行账号    | 直接泄露机密数据，造成实质性隐私侵害  |
| 属性推断攻击     | 推断已知训练集成员的未公开敏感属性 | 基于模型输出反推个体隐藏属性                  | 推测某用户的宗教信仰或疾病史      | 侵犯个人隐私，导致歧视或勒索风险    |
| 训练数据记忆风险评估 | 评估模型对敏感信息的记忆强度    | 构造含敏感模式的查询，检测模型是否泄露关联信息         | 检测模型是否记忆罕见医疗记录或专利文本 | 揭示模型记忆偏好，量化敏感数据暴露概率 |

取攻击等方法，量化模型泄露训练数据中 PII、商业秘密等敏感信息的程度，具体表现为泄露数据量与总量的比值。隐私泄露系数基于数据使用需求矩阵计算，其数值在 0~1 区间内，通过预设规则划分为若干子区间，每个区间对应特定的风险等级。攻击成功率统计在对抗性攻击场景下，模型被成功攻击导致隐私泄露的概率。隐私泄露风险等级是综合上述 3 个指标得出的评估结果，通常划分为低风险、中风险、高风险 3 个等级。这些指标共同构成了模型隐私泄露风险的量化评估体系，为安全防护提供数据支撑<sup>[34]</sup>。

### 2.3.3 常用数据集及工具

在隐私泄露风险评估领域，以下数据集和工具发挥着关键作用。数据集方面，PII-Scope 是由华为慕尼黑研究中心开发的综合性基准数据集，包含多种威胁场景下的隐私泄露样本，可有效验证 LLM 中 PII 提取攻击的检测能力。工具方面，IBM Differential Privacy 提供差分隐私算法实现，在保障隐私安全的前提下支持数据分析与挖掘任务；Privacy Preserving Data Publishing Toolkit 通过数据加噪、混淆和匿名化技术处理敏感信息，既确保数据真实性又满足发布场景需求；GDPR Compliance Benchmark 贯穿数据全生命周期，从采集、处理到应用各环节检测是否符合欧盟通用数据保护条例（General Data Protection Regulation, GDPR）的合规要求。这些工具为隐私风险评估提供了全面的技术支撑。

## 2.4 误导性信息与幻觉评估技术

误导性信息与幻觉评估技术主要用于检测 LLM 生成内容的真实性和可信度，其核心目标是识别模型输出中存在的虚假、误导或与事实不符的信息，防止这些内容对用户产生不良影响。该技术通过系统化的评估方法，帮助开发者发现模型在事实准确性、逻辑一致性等方面的缺陷，为提升模型可靠性提供依据。以下将介绍该领域主流的评估方法、关键评估维度以及常用的数据集和工具。

### 2.4.1 评估方法

误导性信息与幻觉评估技术主要包含以下 5 种评估方法：1) 基于事实的核查通过将模型输出与权威知识库比对，验证历史事件等陈述的真实性<sup>[35]</sup>；2) 基于一致性的评估则通过多角度提问检验回答的稳定性，并计算语义相似度以判断回答的可靠性<sup>[36]</sup>；3) 多模态鲁棒性基准专注于评估模型对多模态数据的处理能力；4) 检索增强生成系统评估不仅要求生成内容质量达标，还需确保检索信息的准确性和可信度<sup>[37]</sup>；5) 人类评估依靠专业人员的知识经验，从主观视角判断信息真实性，为自动化评估提供补充<sup>[38]</sup>。表 5 系统对比了这些评估方法的技术特点与应用场景。

表 5 误导性信息与幻觉评估方法对比

| 评估方法       | 核心机制                       | 适用场景                          | 关键优势                  | 主要局限               |
|------------|----------------------------|-------------------------------|-----------------------|--------------------|
| 基于事实的核查    | 比对模型生成内容与权威知识库 / 信息源，验证真实性 | 历史事件、科学事实等描述的准确性检测            | 直接验证内容真实性，依赖权威来源      | 依赖知识库覆盖范围，无法检测逻辑矛盾 |
| 基于一致性的评估   | 通过不同提问方式测试回答的一致性           | 科学定律、概念解释等多角度提问场景             | 揭示模型内在矛盾，评估输出稳定性      | 不直接验证事实，仅反映逻辑一致性   |
| 多模态鲁棒性基准   | 设计正 / 负向问题测试模型对误导性信息的抵抗能力  | 多模态大模型（文本 + 图像 / 视频）          | 量化模型抗干扰能力，专为多模态场景设计   | 需定制测试集，泛化性依赖基准质量   |
| 检索增强生成系统评估 | 联合评估生成内容质量 + 检索信息的准确性、相关性  | 检索增强生成（RAG）系统 <sup>[39]</sup> | 确保外部知识有效整合，提升结果可解释性   | 需多模块协同评估，复杂度高      |
| 人类评估       | 评估员基于专业知识分析内容，识别幻觉 / 误导    | 需深度语义理解的复杂场景                  | 提供主观洞察，发现自动化方法遗漏的细微错误 | 成本高、可扩展性差，存在主观偏差   |

### 2.4.2 评估指标

误导性信息与幻觉评估技术的核心指标包括准确



率、F1分数、误导率、误报率、鲁棒性准确率、幻觉率和隐私泄露风险等级等。准确率量化模型正确回答问题的比例。F1分数通过平衡准确率与召回率优化信息抽取和问答评估。误导率反映模型对误导性问题的错误响应程度。鲁棒性准确率在严苛条件下测试模型的抗干扰能力。幻觉率直接表征模型生成虚假内容的频率,该数值越低表明输出可靠性越高。隐私泄露风险等级专门评估数据安全风险。这些指标共同构建了多维度的评估体系,能够全面分析文本生成模型的质量与安全性。

### 2.4.3 常用数据集及工具

在误导性信息与幻觉评估领域,以下数据集和工具具有重要应用价值。数据集方面,HateAI-100作为混合数据集,包含人类生成和LLM生成的有害文本样本,能够有效检测模型输出的有害性;MultiJail是首个模拟jailbreak场景的多语言数据集,专门用于测试模型对恶意指令的响应能力及安全漏洞;FactCHD是基于事实冲突的幻觉检测数据集,通过整合多种事实模式并构建证据链提升评估精度;Hallucination eLicitation dataset是经过人工标注的大规模人造句子语料库,为幻觉研究提供标准化数据支持。工具方面,自检GPT基于模型对熟悉主题的一致性响应原则,提供零资源黑盒检测方案;FACTSCORE通过将文本拆解为独立事实单元来评估可靠性;InterrogateLLM采用ROC曲线下的面积(AUC)和平衡准确率(B-ACC)指标量化模型在不同数据集上的幻觉程度;ChainPoll创新性地实现了封闭域/开放域幻觉检测,无需外部模型且效率更高;RAGAS专为检索增强生成系统设计,通过多维度评分检测内容准确性;可信语言模型(Trusted Language Model, TLM)结合自我反思和采样多样性分析,精准识别模型输出中的错误、矛盾及幻觉现象。这些工具共同构建了完善的幻觉检测技术体系。

## 2.5 对抗性攻击与鲁棒性测试技术

对抗性攻击及鲁棒性测试技术主要用于评估LLM在遭受恶意攻击时的稳定性和可靠性,其核心目标是

检测并提升模型抵御对抗性攻击的能力,确保模型在复杂对抗环境下仍能保持正常运行。该技术通过系统化的评估方法,帮助开发者识别模型在对抗场景中的脆弱环节,为模型优化提供数据支持。以下将介绍该领域主流的评估方法、关键评估维度以及常用的实验数据集和评估工具。

### 2.5.1 评估方法

对抗性攻击及鲁棒性测试技术评估主要由红队评估、自动化攻击样本生成、漏洞扫描与模糊测试3个模块构成,共同形成对系统完整性的全面检测体系,如图3所示。




图3 对抗性攻击与鲁棒性测试方法协同关系

其中,红队评估采用目标导向的渗透测试方法,通过模拟真实攻击者的思维模式和行为手段,针对系统特性制定攻击策略,从多角度识别安全漏洞。为克服传统人工测试成本高、周期长的局限,当前研究重点转向自动化攻击生成,包括基于梯度的攻击方法、基于搜索的优化策略以及利用LLM生成攻击性提示等创新手段,并依据世界数字技术院(World Digital Technology Academy, WDTA)提出的《大语言模型安全测试方法》将标准划分为L1~L4不同测试等级。漏洞扫描与模糊测试聚焦已知漏洞类型(如特定提示注入payload)进行专项检测,或通过向LLM输入大量异常值样本来评估模型稳定性。该技术通过系统性的异常输入测试,量化模型对意外输入的抵抗能力,确保其在遭受恶意攻击时仍能保持可靠运行。表6详细对比了各类对抗性攻击与鲁棒性测试评估方法的核心原理、技术手段、适用阶段和攻击级别。

### 2.5.2 评估指标

对抗攻击和鲁棒性测试的核心评价指标主要包括

表 6 对抗性攻击与鲁棒性测试评估方法对比

| 评估方法      | 核心原理                    | 技术手段                                                     | 适用阶段    | 攻击级别                |
|-----------|-------------------------|----------------------------------------------------------|---------|---------------------|
| 红队评估      | 模拟真实攻击者思维，进行全方位渗透测试     | 人工设计攻击场景（如诱导生成非法内容、绕过安全规则）                               | 部署前/后   | 无固定分级               |
| 自动化攻击样本生成 | 通过算法批量生成对抗样本，高效测试模型漏洞   | 基于梯度：利用模型梯度生成扰动<br>基于搜索：启发式搜索攻击路径<br>LLM 生成：用大模型自动构造攻击提示 | 开发/测试阶段 | 按 WDTA 标准分为 L1~L4 级 |
| 漏洞扫描与模糊测试 | 针对已知漏洞定向检测 + 随机异常输入压力测试 | 漏洞扫描：检测预设注入 payload；<br>模糊测试：生成随机异常输入                    | 持续安全监测  | 按漏洞危害定级             |

攻击成功率（ $ASR$ ）、鲁棒性得分、查询次数/成本以及防御难度/有效性。 $ASR$ 量化了在给定攻击预算下模型出现错误行为的概率，该数值越高表明模型越易受攻击，安全性越差；鲁棒性得分反映模型对抗攻击后的准确率或安全率，得分越高说明模型抗干扰能力越强；查询次数/成本指标通过计算成功攻破模型所需的平均尝试次数或资源消耗，直接反映攻击实施难度——次数越少意味着模型安全风险越大；防御难度/有效性评估现有防御措施对特定攻击的抵抗强度。这 4 个指标共同构成模型安全性和鲁棒性的综合评价体系，其中  $ASR$  与鲁棒性得分形成安全性的直接对比，查询次数/成本揭示攻击实施的经济门槛，而防御难度/有效性体现防护系统的实际效能。

### 2.5.3 常用数据集及工具

在对抗性攻击和鲁棒性测试领域，以下数据集和工具发挥着关键作用。数据集方面，OWASP 提供了系统化的红队测试方法论和资源库，包含攻击实施与防御建议的双向指导，能有效帮助安全研究人员识别和修复模型漏洞；SuperCLUE-Safety 是专为中文大模型设计的对抗安全评估基准，通过预训练安全模型对被测模型输出进行量化评分，并给出风险点解析与优化方案；AdvGLUE 作为对抗鲁棒性评测基准，涵盖多种复杂任务场景；TextAttack 是基于 Python 的开源对抗样本生成框架，支持多种攻击算法和模型，显著提升测试效率。工具方面，OWASP 指南为红队测试提供结构化方法论；SuperCLUE-Safety 通过多轮对抗测试实现中文

模型安全性量化评估；AdvGLUE 数据集支持多任务鲁棒性研究；TextAttack 框架能自动匹配攻击算法并生成针对性测试样例。这些工具共同构建了完整的对抗性测试技术体系。

### 2.6 主流 LLM 安全检测评估方法特性

在对主流 LLM 安全检测评估方法的综合分析中，各类方法均展现出独特的优势与局限。偏见和公平性评估通过揭示模型对不同群体的响应差异，为改善模型公平性提供重要依据，但评估流程的复杂性及公平性标准的多样性使其难以实现绝对公平<sup>[16]</sup>。有害内容生成评估借助自动化工具实现高效批量检测，人工审核确保了结果准确性，然而面对新型伪装有害内容时仍存在检测盲区，且不同方法间需形成互补效应<sup>[25]</sup>。隐私泄露风险评估能有效识别模型的数据保护薄弱环节，但攻击模拟技术的高门槛和算力需求，使其在复杂模型和复杂数据分布下的分析难以达到 100% 精准<sup>[34]</sup>。误导信息与幻觉评估显著提升了模型输出的真实性和可靠性，但受限于误导性内容的隐蔽性和幻觉现象的复杂性，事实核查与一致性检验仍存在一定误差，同时基准测试数据集在覆盖范围和更新时效性方面也存在不足<sup>[35]</sup>。对抗性与鲁棒性测试虽能有效发现模型漏洞并提升安全性，但其实施依赖专业知识和实践经验，且需持续更新测试手段以应对新型攻击方式<sup>[36]</sup>。图 4 通过 1~5 分的量化评分体系，系统对比了这些主流评估方法的关键性能指标。




图 4 主流 LLM 安全检测评估方法特性对比

当前各类评估技术在实际应用中都展现出独特的优势与局限性。在具体实践中，需根据实际需求和场



景特点,对这些技术进行合理选择与组合,以实现最优的评估效果。

### 3 大模型安全评估基准与标准

随着LLM应用的日益普及及其安全问题的凸显,建立统一、权威的安全评估基准已成为行业发展的关键需求。该基准不仅能为模型设计者提供安全优化方向,还可为使用者及监管机构提供客观评判依据,对推动技术可信化与行业规范化具有深远意义。

#### 3.1 国际主要评估基准与标准

国际上多个标准化组织与研究机构已启动LLM安全评估的标准化工作,旨在为行业提供统一的评估框架与方法论。

##### 3.1.1 OWASP LLM 安全验证标准

由OWASP发布的《OWASP LLM安全验证标准》(OWASP LLMVS)是针对人工智能及LLM系统的开放性安全规范,该标准从架构设计、模型生命周期管理、训练流程、操作集成、存储监控等维度提出系统性要求,并提供了涵盖安全准则、审计方法等内容的完整解决方案,专门应对LLM特有的功能性与非功能性安全问题。标准进一步通过具体实施路径的指导,帮助开发人员落实安全措施,并辅助安全团队开展检测、渗透测试等工作。其最新稳定版本为0.1(2024年2月发布)。作为国际通用标准,OWASP LLMVS虽在技术安全性层面具有普适性,可适配不同国家和地区的应用场景,但也可能因文化差异导致对特定区域安全需求的覆盖不足。

##### 3.1.2 IEEE P3419 标准

由IEEE计算机学会/人工智能标准委员会P3419工作组牵头编制的LLM及多模态模型测评标准,建立了以多功能性、智能、效率和安全性为基本原则的三维测评框架。该框架通过能力—任务—指标分类体系,实现了从基础模型、预训练算法到微调算法的全流程测评覆盖,确保各阶段评估内容的合理性与有效性。作为国际技术标准,IEEE P3419侧重技术通用性与普

适性,其评估体系主要从技术维度出发,为全球LLM发展提供指导,但对地域文化差异的考量相对有限。

##### 3.1.3 NIST AI 风险管理框架

由美国国家标准与技术研究院(National Institute of Standards and Technology, NIST)发布的《AI风险管理框架》(NIST-AI-RMF),系统阐述了适用于各类AI系统的治理措施,涵盖风险识别机制、利益相关方沟通策略等核心内容,并明确了治理方法的应用目标。该框架并非专为LLM设计,但其提出的治理、映射、测量和管理四维体系,以及透明度、可解释性、鲁棒性、公平性等原则,仍为LLM的安全评估与治理提供了重要理论支撑。作为通用性框架,NIST-AI-RMF主要从技术与管理双重视角出发,通过普适性风险治理原则的制定,为全球不同地区的AI系统治理提供标准化指导。

##### 3.1.4 其他有影响力的国际基准

斯坦福大学发布的语言模型的全面评估(Holistic Evaluation of Language Models, HELM)等工具虽以模型性能测试为主,但已将鲁棒性、公平性及偏见等安全要素纳入评估体系。针对LLM面临的网络安全威胁,WDTA提出的安全测试方法通过L1随机、L2盲盒、L3黑盒和L4白盒4类攻击模式,以ASR和性能下降率(DR)为量化指标,系统评估模型的抗攻击能力。这类评估框架虽在技术安全性与性能层面具有普适性,但更侧重通用性技术指标,对特定应用场景的适配性可能不足。

#### 3.2 国内主要评估基准与标准

我国在LLM安全评估标准化领域已取得显著进展,政府部门、研究机构及行业联盟共同参与构建了具有中国特色的评估体系。该体系通过多层级基准与规范性文件的制定,形成了如图5所示的系统化评估框架。下面将重点介绍这些核心评估标准与规范文件的具体内容。

##### 3.2.1 TC260 人工智能安全治理框架

由全国信息安全标准化技术委员会(TC260)发




图5 系统化评估框架

布的《人工智能安全治理框架》作为全球AI治理倡议的重要实施文件，系统构建了AI安全治理的完整指南。该框架确立以人为本、向善发展、包容审慎、敏捷治理、技术与管理结合、开放合作等6项核心原则，创新性地将AI安全风险划分为固有风险（涵盖模型算法风险、数据风险等）与应用风险两大类，并针对性地提出技术解决方案、综合治理策略及面向模型开发者、服务提供商、使用者的分级安全指引。

### 3.2.2 中文 LLM 安全评估基准

由北京智源人工智能研究院与清华大学等机构联合共建的中文LLM安全评估基准，创新性地采用8种典型指令攻击与6种高难度攻击类型构建评估体系。该基准通过设计评测提示—分析模型响应的双维评估机制，系统测评模型的安全性能，其核心成果包括开源发布的SafetyPrompts数据集（含10万条测试提示与响应数据），为构建安全、负责任、符合伦理的AI发展范式提供重要支撑。

清华大学联合腾讯发布的《大语言模型（LLM）安全性测评基准》进一步强化了评估体系。作为具有中国特色的安全标准，该基准将内容安全与意识形态安全作为核心评估维度，既体现技术伦理要求，又符合中国法律法规的特殊性，形成技术规范与价值引领相融合的评估范式。

### 3.2.3 TC260 生成式人工智能服务安全基本要求

由TC260发布的《生成式人工智能服务安全基本要求》（GB/T 45654-2025）作为技术指导规范，虽非强

制性标准，但为生成式AI服务提供了系统性安全框架。该规范在训练数据安全层面创新性提出双4000抽样检测机制，要求服务方从每个语料库随机选取4000个样本点，确保非法有害信息占比严格控制在5%以内；在内容安全领域构建2000题动态测试体系，规定题库规模不低于2000题，实际测试需覆盖1000题且通过率需达90%，同时要求建立包含1万余关键词的敏感词库并实施风险对话审查机制。作为具有中国特色的技术规范，该标准将社会主义核心价值观作为核心价值导向，明确禁止生成危害国家安全、社会稳定及民族团结的内容，既体现技术伦理要求，又符合中国法律法规的特殊性，形成技术规范与价值引领相融合的治理范式。

### 3.2.4 CESI 中国大模型标准符合性评测

由中国电子技术标准化研究院（China Electronics Standardization Institute, CESI）在工信部指导下发起的中国大模型标准符合性评测，构建了覆盖多模态、多领域、多维度的评估框架与指标体系。该评测体系全面考察大模型的通用能力、智能能力及安全能力三大核心维度，支持文本、语音、视觉等多种模态的评估需求。首批通过评测的包括360集团昆仑大模型、百度文心一言大模型、腾讯混元大模型以及阿里云通义千问大模型等国内领先产品。该评测体系不仅为行业提供合规性参考目录，更通过标准化评估引导产业健康发展。

### 3.3 各类基准与标准的比较分析

通过对比分析国内外主流LLM安全评估体系，可以发现这些标准虽各有侧重，但核心目标高度一致——提升模型的安全性与可信度。LLM安全评估标准/框架关注点对比如图6所示。

OWASP LLMVS作为应用安全领域的实践指南，为开发者和安全工程师提供了覆盖软件全生命周期的可操作性安全验证清单；IEEE P3419着力构建多维度的能力评估框架，将安全性指标纳入科学系统化的测评体系；NIST AI RMF从风险管理视角出发，为各类




图6 LLM 安全评估标准 / 框架关注点对比

AI系统提供通用性治理原则。我国标准体系在技术安全基础上，更强调内容安全与意识形态合规性，如TC260《生成式人工智能服务安全基本要求》不仅详细规定数据审核流程，更将社会主义核心价值观作为核心要求。这些标准共同推动行业评价体系走向规范化，既为开发者提供安全设计指引，也为监管机构建立评估依据。随着技术快速迭代，未来标准需持续关注对抗性攻击防御、多模态安全等新挑战，在守住安全底线的同时保持技术发展空间。

#### 4 大模型安全对齐技术的作用与评估

LLM对齐是指通过特定方法和技术手段，使模型的行为、输出及内在目标与人类价值观、偏好和期望保持一致的过程。对于多数应用场景而言，安全对齐能有效降低模型生成有害、偏见性、不真实或不符合预期内容的风险，为模型安全提供重要保障。本章将重点探讨主流LLM安全对齐技术对模型功能安全性的提升作用，并说明相应的安全效果评估方法<sup>[40,41]</sup>。

##### 4.1 主流安全对齐技术及其安全增强机制

目前，学术界和产业界已探索并应用了多种LLM对齐技术，这些技术通过不同机制引导模型向更安全、可信的方向发展。

###### 4.1.1 基于人类反馈的强化学习

基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）是目前较有效的模型对齐方法，其具体实施流程包含4个关键步骤：首先，通过人工标注或排序打分的方式收集人类对模型生成内容的偏好信息，包括回答的安全性、实用性及相关性

等维度；其次，利用这些偏好数据训练奖励模型（Reward Model, RM），使其能够将符合人类价值观的响应映射为更高分值；再次，通过RM对LLM输出内容进行质量评估，并据此调整模型权重以优化输出结果；最后，采用近端策略优化（Proximal Policy Optimization, PPO）算法在更新模型权重时确保训练过程的稳定性。RLHF的安全增强机制主要体现在引导模型规避有害内容、减少偏见输出、确保回答真实性及遵循指令要求等方面，通过持续优化使模型行为与人类价值观趋同，从而有效提升功能安全性并降低输出风险<sup>[42]</sup>。

作为主流的对齐技术，RLHF虽取得显著成效，但仍存在多方面局限性。人类偏好数据的采集不仅成本高昂，还易受收集过程偏差影响，制约了技术的大规模应用。评估者对事实性和适当性标准的理解存在主观差异，难以建立统一的评判基准。更值得注意的是，评估者可能因操作失误或恶意行为干扰模型训练。此外，当反馈数据来源受限时，模型易出现群体适应性不足或偏见放大问题。从技术实现层面看，RLHF需先构建奖励模型再实施强化学习微调，不仅流程复杂、计算资源消耗大，还面临训练稳定性挑战。

###### 4.1.2 直接偏好优化

直接偏好优化（Direct Preference Optimization, DPO）是一种无需显式奖励模型的训练方法，其核心机制是通过成对的偏好数据（好与坏回答）直接指导模型策略优化。该方法通过强制模型优先输出被标注为安全无害的响应，同时抑制不安全或有害内容的生成，有效提升模型安全性。然而，现有研究表明该方法在拒绝学习场景存在局限性：当面对非法或危险性问题（如制造炸弹的指导）时，由于训练数据中缺乏此类问题的明确拒绝标注（即便存在标注也可能被误判为无害），模型可能将必要的安全拒绝行为与普通安全响应等同对待，未能有效识别潜在危险内容的特殊性<sup>[43]</sup>。

DPO通过重构策略模型的损失函数实现高效对齐，其技术优势主要体现在3个方面：首先，通过直接增加偏好样本生成概率并降低非偏好样本概率，实现了



人类偏好的显式嵌入；其次，相比传统RLHF方法省去了奖励函数学习和策略采样环节，显著简化了训练流程；最后，由于对超参数敏感性较低，模型训练过程具有更好的稳定性。这种直接优化策略的创新方法，在保持对齐效果的同时提升了训练效率。

#### 4.1.3 对比偏好优化 / 上下文偏好优化

与DPO相比，对比偏好优化（Contrastive Preference Optimization, CPO）作为上下文偏好优化的进阶变体，通过两种创新机制有效弥补了DPO的安全缺陷：首先，采用更精细的优化目标设计，通过对比学习或强化损失函数捕捉人类偏好的细微差异，使模型能够区分优质回答与次优响应，从而在参数调整过程中更精准地遵循价值观与安全规范；其次，通过动态整合环境上下文信息，实现情境化安全策略调整——例如在医疗咨询场景中自动规避误导性建议。CPO采用多目标对比学习框架，同步优化有用性、无害性等维度，避免单一目标的过度拟合，最终在确保安全性的同时生成合理响应。

#### 4.1.4 逆强化学习

逆强化学习（Inverse Reinforcement Learning, IRL）是通过分析专家行为推导隐含奖励函数，进而利用该函数训练模型以模拟专家行为的技术。与之形成对比的自洽性经验对齐（Alignment from Demonstration, AfD）方法则直接通过高质量参考样本（即经验数据）来优化模型行为，无需显式推导奖励函数。这两种方法在安全增强方面各具优势。首先，通过从优质场景中学习安全行为模式，使模型能够根据不同情境作出适应性安全响应；其次，显著降低对偏好标注数据的依赖，有效规避大规模标注带来的成本高、劳动强度大及标注不确定性等问题；再次，由于训练样本的多样性和代表性，模型在面对未见场景时展现出更强的泛化能力和安全决策能力；最后，通过严格筛选的高质量数据指导，确保模型在特定情境下输出的内容既符合准确性要求，又能避免对身心健康造成危害，例如杜绝诽谤性言论或偏离预期的有害偏见倾向<sup>[44]</sup>。

#### 4.1.5 双目标优化方法

当前主流对齐方法在应对越狱式攻击等安全威胁时仍存在明显不足，为此研究者提出一种双目标优化（Dual-Objective Optimization, DOO）方法。该方法通过两个核心机制实现安全增强：1）鲁棒拒绝训练，使模型具备逐字逐句检测输入安全性的能力，通过持续优化对不安全输入的敏感度，可在识别威胁性内容时立即终止生成；2）有害知识反学习，主动消除模型可能产生有毒输出的知识模式。DOO架构核心设计如图7所示。




图7 DOO架构核心设计

这种双目标架构通过解耦安全控制维度，使模型能够针对不同安全要素进行精准优化，其防御机制不仅可有效应对前缀填充、后缀攻击等复杂越狱手段，还能在各类潜在攻击场景中保持高安全性，将有害内容生成概率降至最低，从而显著提升模型输出的稳定性和可靠性<sup>[45]</sup>。

#### 4.2 对齐效果的评估

评估LLM安全对齐技术的有效性需建立多维度的评估体系，详情如图8所示。




图8 LLM安全对齐评估体系

该体系主要包含5个核心评估维度：有害输出减少指标通过对比对齐前后模型在标准测试集及对抗测试中的输出结果，量化有害内容生成频率及危害程度的降低幅度；攻击抵抗力测试则通过评估模型在遭受提示注入、越狱等主流攻击手段后的防御成功率，反

映其在真实场景中的安全防护能力；对齐损耗测量关注安全对齐可能带来的副作用,包括通用能力、创造性、事实正确性等维度的性能衰减,以识别对齐过当现象；DOO泛化能力测试通过新颖提示、新场景及攻击变种等输入,验证模型在未知情境下的安全稳定性；可解释性分析则要求模型能清晰说明安全决策逻辑,如拒答特定提问或选择安全回答形式的依据。此外,人工综合评估通过人类评价员对模型输出的安全性、适当性、可信度等主观感受进行验证,结合自动化测试与对抗性测试,形成闭环评估机制。值得注意的是,当前安全对齐技术仍面临越狱攻击的挑战,且过度对齐可能导致模型保守化,因此如何在安全性与实用性之间取得平衡,仍是该领域亟需解决的关键问题<sup>[45]</sup>。

## 5 挑战与未来展望

尽管已有较多针对LLM的安全检测评估技术手段,但由于LLM本身具有规模庞大、结构复杂、能力快速迭代以及安全风险动态更新等特性,其安全检测评估工作仍面临显著挑战。本章将系统分析当前LLM安全检测评估领域存在的主要技术瓶颈,并对其未来研究方向与发展趋势进行前瞻性探讨。

### 5.1 当前面临的主要挑战

当前LLM安全评估面临的主要问题可归纳为以下几个方面。首先,评估体系的覆盖性与时效性存在局限,现有评估维度难以全面应对已知攻击手段,尤其对隐蔽性强、欺骗性高的新型攻击手段缺乏有效识别机制,而静态评估标准与快速演化的风险态势之间存在显著滞后性<sup>[46]</sup>；其次,评估方法及指标的科学性有待提升,部分评估因依赖缺陷数据集导致结果偏差,自动化评估工具在客观性和稳定性方面表现不足,现有指标与实际应用场景的匹配度较低；再次,评估基准数据建设面临挑战,构建覆盖全面、实时更新、成本可控且标注便捷的高质量数据集存在较大难度；此外,对抗性评估陷入技术博弈困境,红队测试受限于“军备竞赛”效应,对抗自动攻击技术难以模拟真实复杂攻击场景,安全对齐技术与攻击手段的持续博弈进一步加剧了评

估难度；最后,新兴场景带来全新挑战,多模态输入攻击的多样性、LLM Agent未授权输入引发的安全责任归属等问题<sup>[47]</sup>,以及“对齐税”导致的模型安全性与能力平衡难题,均对现有评估体系构成严峻考验。

### 5.2 未来研究方向与建议

针对LLM安全检测评估面临的系统性挑战,未来需构建涵盖技术工具、数据基准、标准协作、治理实践4个维度的立体化动态长效机制。该机制将充分适应大模型快速迭代的特性,通过多维度协同创新满足持续演进的安全保障需求。以下从4个关键层面展开具体建设路径。

1) 技术与工具层面:需构建具备动态自适应的评估框架,整合持续学习、在线评估和元学习等技术手段,使评估体系能实时响应LLM能力演进与安全风险变化。重点提升自动化评估工具在准确性、鲁棒性和可解释性方面的表现,同时加强对LLM-as-a-judge机制的可靠性验证。通过因果推断和模型可解释性研究,建立安全调整的决策依据。特别针对多模态输入攻击和LLM Agent外设影响等新兴风险,需同步研发评估标准与防护机制。

2) 数据与基准层面:应建设开放透明的基准平台,通过社会化协作实现评价体系标准化。该平台需持续更新安全评估数据集、工具库和排行榜,支持多场景攻击模拟与安全度评估,为研究者和实践者提供可对比、可复现的资源。通过标准化数据采集和评估流程,既能推动技术发展,又能确保结果公平性,形成良性循环的创新生态。

3) 标准与合作层面:需建立攻防对抗标准体系,研发红队测试工具和对抗攻击生成技术,开发真实攻击场景模拟平台。重点研究鲁棒防御方法和安全对齐技术,提升模型对未知攻击的泛化能力。通过理论验证和形式化手段,构建可解释的安全标准框架。同时加强跨学科协作与国际合作,促进知识共享与标准统一,形成应对跨国安全威胁的协同防御网络。

4) 治理与实践层面:需将安全治理贯穿LLM全

生命周期,从数据采集到模型部署各环节实施精细化管控。结合行业特性制定差异化安全指标,针对不同场景风险特点开发专项评价标准与实践指南。通过全流程安全评估与保障机制,实现安全治理与模型应用的动态平衡,为LLM的可靠落地提供系统性支撑。

## 6 结束语

本文系统研究了LLM安全检测评估技术体系,重点探讨了偏见与公平性、有害内容生成、隐私泄露、误导性信息及幻觉、对抗攻击与鲁棒性测试等核心领域的技术特征。通过分析各领域的评价方法、关键指标、基准数据集及工具链,全面梳理了现有技术的优势、局限性与适用场景。同时,对国内外主流安全评估标准与基准进行了对比研究,论证了标准化建设对行业规范发展的重要价值。在安全对齐技术方面,深入剖析了其实现原理、技术贡献及实践挑战,并创新性地提出了效果评估方法论。尽管当前研究已取得阶段性进展,但评估体系仍存在维度单一、动态性不足、方法学可靠性存疑等突出问题,特别是在基准数据集建设、对抗性评估以及跨模态/Agent场景测试等前沿领域面临显著挑战。未来研究将聚焦动态评估框架构建、智能可解释技术研发、开放基准平台建设、攻防体系创新及安全对齐验证等方向,这些突破性进展的实现亟需跨学科、跨领域的协同创新与深度合作。

### 参考文献:

- [1] YAO Yifan, DUAN Jinhao, XU Kaidi, et al. A Survey on Large Language Model (LLM) Security and Privacy: The Good, the Bad, and the Ugly[J]. High-Confidence Computing, 2024, 4(2): 100211-100233.
- [2] WANG Qiaochen, WU Zhengang, LIU Hu. Overview of Security and Privacy Issues in the Application of Large Language Models[J]. Industrial Information Security, 2024(5): 40-45.  
王乔晨, 吴振刚, 刘虎. 大语言模型应用的安全与隐私问题综述[J]. 工业信息安全, 2024 (5): 40-45.
- [3] HOU Chao, MIAO Haoyu, BAO Tianyuan, et al. A Brief Discussion on the Application of Large Models in Cybersecurity[J]. Network Security and Informatization, 2025(3): 1-3.  
侯超, 苗浩宇, 鲍天远, 等. 浅谈大模型在网络安全中的应用[J]. 网络安全和信息化, 2025 (3): 1-3.
- [4] TIMPERLEY R L, BERTHOUD L, SNIDER C, et al. Assessment

of Large Language Models for Use in Generative Design of Model Based Spacecraft System Architectures[J]. Journal of Engineering Design, 2025, 36(4): 550-570.

[5] TAI Jianwei, YANG Shuangning, WANG Jiajia, et al. Survey of Adversarial Attacks and Defenses for Large Language Models[J]. Journal of Computer Research and Development, 2025, 62(3): 563-588.

台建伟, 杨双宁, 王佳佳, 等. 大语言模型对抗性攻击与防御综述[J]. 计算机研究与发展, 2025, 62 (3): 563-588.

[6] ZHANG Ran, LI Hongwei, QIAN Xinyuan, et al. On Large Language Models Safety, Security, and Privacy: A Survey[J]. Journal of Electronic Science and Technology, 2025, 23(1): 100301-100311.

[7] ETSI. Aqua Security Listed in OWASP's LLM and Generative AI Security Solutions Landscape Guide for 2025[J]. Manufacturing Close-Up, 2024(12): 1-7.

[8] KUANG Hongyu. Research on Key Technologies for Software Vulnerability Detection Based on Pre-Trained Language Models[D]. Beijing: Academy of Military Sciences, 2024.

匡洪宇. 基于预训练语言模型的软件漏洞检测关键技术研究[D]. 北京: 军事科学院, 2024.

[9] LI Jihong, YU Yanfang, YU Qiwei, et al. Chinese Open Relation Extraction Based on Large Language Model and Multi-Dimensional Self-Reflective Learning[EB/OL]. (2025-05-30)[2025-06-01]. <http://kns.cnki.net/kcms/detail/10.1478.G2.20250530.1140.002.html>.

李翼鸿, 余燕芳, 余奇伟, 等. 基于大语言模型与多维度自我反思学习的中文开放关系抽取[EB/OL]. (2025-05-30)[2025-06-01]. <http://kns.cnki.net/kcms/detail/10.1478.G2.20250530.1140.002.html>.

[10] YANG Jirui, LIN Zheyu, YANG Shuhan, et al. Concept Enhancement Engineering: A Lightweight and Efficient Robust Defense against Jailbreak Attacks in Embodied AI[EB/OL]. (2025-04-15)[2025-06-01]. <https://arxiv.org/abs/2504.13201>.

[11] SHI Dan, SHEN Tianhao, HUANG Yufei, et al. Large Language Model Safety: A Holistic Survey[EB/OL]. (2024-12-23)[2025-06-01]. <https://arxiv.org/abs/2412.17686>.

[12] ANDERSON S C, SUMMERS D, OUYANG M, et al. Safety and Efficacy of Low-Intensity Versus Standard Monitoring Following Intravenous Thrombolytic Treatment in Patients with Acute Ischaemic Stroke (OPTIMISTmain): An International, Pragmatic, Stepped-Wedge, Cluster-Randomised, Controlled Non-Inferiority Trial[J]. The Lancet, 2025, 4(5): 1909-1922.

[13] WANG Kun, ZHANG Guibin, ZHOU Zhenhong, et al. A Comprehensive Survey in LLM(Agent) Full Stack Safety: Data, Training and Deployment[EB/OL]. (2025-04-22)[2025-06-01]. <https://arxiv.org/abs/2504.15585>.

[14] NI Bo, LIU Zheyuan, WANG Leyao, et al. Towards Trustworthy Retrieval Augmented Generation for Large Language Models: A Survey[EB/OL]. (2025-02-08)[2025-06-01]. <https://arxiv.org/abs/2502.06872>.

[15] ZHANG Xuewang, LU Hui, XIE Haoifei. A Data Augmentation Method Based on Graph Node Centrality and Large Model for Vulnerability Detection[J]. Netinfo Security, 2025, 25(4): 550-563.

张学旺, 卢荟, 谢昊飞. 基于节点中心性和大模型的漏洞检测数据



增强方法[J]. 信息安全, 2025, 25(4): 550-563.

[16] GUO Xiangxin, LIN Jingqiang, JIA Shijie, et al. Security Analysis of Cryptographic Application Code Generated by Large Language Model[J]. Netinfo Security, 2024, 24(6): 917-925.

郭祥鑫, 林璟铨, 贾世杰, 等. 针对大语言模型生成的密码应用代码安全性分析[J]. 信息安全, 2024, 24(6): 917-925.

[17] BEVARA K V R, MANNURU R N, KAREDLA P S, et al. Scaling Implicit Bias Analysis across Transformer-Based Language Models through Embedding Association Test and Prompt Engineering[J]. Applied Sciences, 2024, 14(8): 3483-3492.

[18] QU Youzhi, WEI Chen, DU Penghui, et al. Integration of Cognitive Tasks into Artificial General Intelligence Test for Large Models[J]. IScience, 2024, 27(4): 50-59.

[19] KURUMAYYA V. Towards Fair AI: A Review of Bias and Fairness in Machine Intelligence[J]. Journal of Computational Social Science, 2025, 8(3): 55-65.

[20] SONG Jiale, ZUO Xingquan, ZHANG Xiujian, et al. Overview of Evaluation Methods for Large Language Models[J]. Aerospace Measurement Technology, 2025, 45(2): 1-30.

宋佳磊, 左兴权, 张修建, 等. 大语言模型评估方法综述[J]. 宇航计测技术, 2025, 45(2): 1-30.

[21] RAVINDRANATH R, STEIN D J, BOUSSARD H T, et al. The Impact of Race, Ethnicity, and Sex on Fairness in Artificial Intelligence for Glaucoma Prediction Models[J]. Ophthalmology Science, 2025, 5(1): 100596-100608.

[22] BROWN E K, YAN Chao, LI Zhuohang, et al. Large Language Models Are Less Effective at Clinical Prediction Tasks than Locally Trained Machine Learning Models[J]. Journal of the American Medical Informatics Association: JAMIA, 2025, 32(5): 811-822.

[23] CHEN Haoling, LIU Peng. Stock Return Prediction Using Financial News: A Unified Sequence Model Based on Hierarchical Attention and Long-Short Term Memory Networks[C]//IEEE. International Conference on Signal Processing and Machine Learning (CONF-SPML 2021). New York: IEEE, 2021: 147-152.

[24] ZHANG Zhanfeng, MA Hongfeng, JIANG Xin. Overview of Bias Assessment and Correction for Pre-Trained Language Models[EB/OL]. (2025-05-22)[2025-06-01]. <http://kns.cnki.net/kcms/detail/42.1671.TP.20250521.1617.014.html>.

张展峰, 马宏伟, 姜鑫. 预训练语言模型的偏见评估与纠正综述[EB/OL]. (2025-05-22)[2025-06-01]. <http://kns.cnki.net/kcms/detail/42.1671.TP.20250521.1617.014.html>.

[25] PARDHI P. Content Moderation of Generative AI Prompts[J]. SN Computer Science, 2025, 6(4): 329-336.

[26] AGHA S D M, WAZZAN A A F. Evaluating the Impact of Gypsum Content on the Physical and Hydraulic Properties of Soils in Arid Regions: A Review[J]. Asian Journal of Soil Science and Plant Nutrition, 2025, 11(1): 217-225.

[27] XU Zhiwei, LI Hailong, LI Bo, et al. Overview of AIGC Large Model Evaluation: Enabling Technologies, Security Risks, and Countermeasures[J]. Computer Science and Exploration, 2024, 18(9): 2293-2325.

许志伟, 李海龙, 李博, 等. AIGC大模型测评综述: 使能技术、安全隐患和应对[J]. 计算机科学与探索, 2024, 18(9): 2293-2325.

[28] XIE Yueqi, FANG Minghong, PI Renjie, et al. GradSafe: Detecting Jailbreak Prompts for LLMs via Safety-Critical Gradient Analysis[EB/OL]. (2024-12-21)[2025-06-01]. <https://arxiv.org/abs/2402.13494>.

[29] LI Jie, LI Zhengfang, ZOU Yao, et al. Evaluation Method for Multi-Language Word Alignment Capability of Large Language Models[J]. Journal of Southwest Minzu University (Natural Science Edition), 2024, 50(6): 681-688.

李洁, 李正芳, 邹焱, 等. 大语言模型多语言词对齐能力评测方法[J]. 西南民族大学学报(自然科学版), 2024, 50(6): 681-688.

[30] XIE Lixia, SHI Jingchen, YANG Hongyu, et al. Member Inference Attack Based on Graph Neural Network Model Calibration[J]. Journal of Electronics and Information Technology, 2025, 47(3): 780-791.

谢丽霞, 史镜琛, 杨宏宇, 等. 基于图神经网络模型校准的成员推理攻击[J]. 电子与信息学报, 2025, 47(3): 780-791.

[31] CUI Qimei, YOU Xiaohu, WEI Ni, et al. Overview of AI and Communication for 6G Network: Fundamentals, Challenges, and Future Research Opportunities[EB/OL]. (2025-04-03)[2025-06-01]. <http://kns.cnki.net/kcms/detail/11.5847.TP.20250403.1018.008.html>.

[32] HAN Zhen, ZHOU Wen'an, HAN Xiaoxuan, et al. Black-Box Membership Inference Attacks Based on Shadow Model[J]. The Journal of China Universities of Posts and Telecommunications, 2024, 31(4): 1-16.

[33] RAN Lingqin, PENG Changgen, XU Dequan, et al. Privacy Leakage Risk Assessment Method Based on Blockchain Technology Architecture[J]. Computer Engineering, 2023, 49(1): 146-153.

冉玲琴, 彭长根, 许德权, 等. 基于区块链技术架构的隐私泄露风险评估方法[J]. 计算机工程, 2023, 49(1): 146-153.

[34] ZHOU Xin, WEYSOW M, WIDYASARI R, et al. LessLeak-Bench: A First Investigation of Data Leakage in LLMs across 83 Software Engineering Benchmarks[EB/OL]. (2025-02-10)[2025-06-01]. <https://arxiv.org/abs/2502.06215>.

[35] DING Jie. Research on Identifying Fake News about Epidemics Based on Deep Learning[D]. Hangzhou: Zhejiang Gongshang University, 2023.

丁杰. 基于深度学习的信息疫情假新闻甄别研究[D]. 杭州: 浙江工商大学, 2023.

[36] MENG Jiachun, FANG Jing, ZHOU Ziqi, et al. Vehicle Collision Sound Recognition Method Based on Convolutional Neural Network[EB/OL]. (2025-05-27)[2025-06-01]. <http://kns.cnki.net/kcms/detail/11.2121.O4.20250527.0813.002.html>.

孟家醇, 方靖, 周子奇, 等. 基于卷积神经网络的车辆碰撞声识别方法[EB/OL]. (2025-05-27)[2025-06-01]. <http://kns.cnki.net/kcms/detail/11.2121.O4.20250527.0813.002.html>.

[37] SUN Jin, HU Zhiyu. Follow-Up on Antitrust Regulation of Generative Artificial Intelligence under Open-Source Model[EB/OL]. (2025-05-29)[2025-06-01]. <http://kns.cnki.net/kcms/detail/61.1352.C.20250528.2203.004.html>.

孙晋, 胡智钰. 开源模式下生成式人工智能的反垄断监管跟进[EB/OL]. (2025-05-29)[2025-06-01]. <http://kns.cnki.net/kcms/detail/61.1352.C.20250528.2203.004.html>.

[38] GUAN Tianrui, LIU Fuxiao, WU Xiyang, et al. HallusionBench: An

Advanced Diagnostic Suite for Entangled Language Hallucination and Visual Illusion in Large Vision-Language Models[EB/OL]. (2023-02-23)[2025-06-01]. <https://arxiv.org/abs/2310.14566>.

[39] DU Yanrui, ZHAO Sendong, ZHAO Danyang, et al. MoGU: A Framework for Enhancing Safety of Open-Sourced LLMs While Preserving Their Usability[EB/OL]. (2024-05-23)[2025-06-01]. <https://arxiv.org/pdf/2405.14488>.

[40] HAZRA R, LAYEK S, BANERJEE S, et al. Safety Arithmetic: A Framework for Test-Time Safety Alignment of Language Models by Steering Parameters and Activations[EB/OL]. (2024-07-17)[2025-06-01]. <https://arxiv.org/abs/2406.11801>.

[41] YI Xin, ZHENG Shunfan, WANG Linlin, et al. NLSR: Neuron-Level Safety Realignment of Large Language Models against Harmful Fine-Tuning[EB/OL]. (2024-12-17)[2025-06-01]. <https://arxiv.org/pdf/2412.12497v1>.

[42] HAIDER Z, RAHMAN H M, DEVABHAKTUNI V, et al. A Framework for Mitigating Malicious RLHF Feedback in LLM Training Using Consensus Based Reward[J]. Scientific Reports, 2025, 15(1): 9177-9184.

[43] WANG Jie, WANG Zitong, PENG Yan, et al. Research on the Prediction of Popularity of Multimodal Social Media Information Based on Large Language Models[J]. Journal of Communications, 2024, 45(11): 141-156.

王洁, 王子瞳, 彭岩, 等. 基于大语言模型的多模态社交媒体信息流行度预测研究[J]. 通信学报, 2024, 45(11): 141-156.

[44] ZHAO Liang. TS-HTFA: Advancing Time-Series Forecasting via Hierarchical Text-Free Alignment with Large Language Models[J]. Symmetry, 2025, 17(3): 401-410.

[45] ZHANG Xiaoyu, ZHANG Cen, LI Tianlin, et al. JailGuard: A Universal Detection Framework for LLM Prompt-Based Attacks[EB/OL]. (2023-12-17)[2025-06-01]. <https://arxiv.org/abs/2312.10766>.

[46] XIANG Yawen, ZHOU Heng, LI Chengyang, et al. Deep Learning in Motion Deblurring: Current Status, Benchmarks and Future Prospects[J]. The Visual Computer, 2024, 41(6): 1-27.

[47] YANG Hong, WU Jun, GUAN Xinpeng. A Survey of Joint Security-Safety for Function, Information and Human in Industry 5.0[J]. Security and Safety, 2025, 4(1): 56-106.